





# 1. Gaussian Process for Regression

(1) (2) Plot the prediction result





(3) Show the corresponding root-mean-square errors

[0, 0, 0, 1]

Training RMSE = 3.1292014298222437

Testing RMSE = 3.3443986601861146

[1, 16, 0, 0]

Training RMSE = 2.4239279278312194

Testing RMSE = 2.668051750252446

[1, 16, 0, 4]

Training RMSE = 2.4105764871252053


Testing RMSE = 2.656998000166914

```
[1, 64, 32, 0]
Training RMSE = 1.0428861621832162
Testing RMSE = 1.1627590936118706
```

(4)

我使用的是 trial and error 來調整看看超參數。我先把全部的參數都調

成 64 嘗試看看，結果如下。




```
[64, 64, 64, 64]
Training RMSE = 0.6989589734393324
Testing RMSE = 1.0781207291422465
```

可以發現結果表現並不差。而從上題可以發現，助教給的第四個參數通


常都很小，因此我懷疑它不是個重要的參數，調成 0 來嘗試看看，結

果如下。



[64, 64, 64, 0]  
 Training RMSE = 0.6990244741065749  
 Testing RMSE = 1.0767940009808907


發現結果是差不多的，但根據之前所學，他很有可能是 regularization 項，因此我決定把它都設為 1。同樣的，第一個參數似乎也都不大，我嘗試看看把它設成 1，結果如下。



[1, 64, 64, 1]  
 Training RMSE = 1.041891402963529  
 Testing RMSE = 1.1618014328537425

結果表現變得比較差，所以我決定還是將前三個參數一起調整。而現在


嘗試看看調成更大的數 128，結果如下。



```
[128, 128, 128, 1]
Training RMSE = 0.6739860328758832
Testing RMSE = 1.076624364195028
```

結果似乎又更好了一點，若是再調大數字，或許結果會更好，我再將數

字調成 256，結果如下。



```
[256, 256, 256, 1]
Training RMSE = 0.6134016439363199
Testing RMSE = 1.189664930176389
```

可發現產生了 over-fitting 的現象，代表參數也不能設太大。於是我選用[128,128,128,0]作為模型較好的超參數。

(5) Explain your findings and make some discussion.

藉由實際調整參數可發現其對模型影響的重要程度，若參數太小很難去 fit training data，而太大又會造成 over-fitting 的結果，引此求得最佳超參數十分重要。第四個超參數看起來雖然不重要，但根據之前所學，或許它具有 regularization 的功能，避免模型過度擬合。

## 2. Support Vector Machine

(1)

one-versus-the-rest:

訓練時將某個類別的樣本歸為一類，其餘樣本歸為另一類。因此有 K 個類別就建構出 K 個 SVM 模型。分類時再計算樣本與每類的相關值，最大即為該類。此種方法可能存在 Bias。

one-versus-one:

訓練時在任一兩類樣本之間設計 SVM，因此當有 K 個類別樣本時就需


要 $(K-1)K/2$  個 SVM 模型。分類時在各模型間計算獲得最多分數的即為

該類。在類別較多時模型數跟計算量可能會較大。


在此題只有 3 類且資料量不算太大的情況下兩種方法表現是差不多的，

我自己選用 ovo 來完成此題。

(2) Linear kernel



(3) Polynomial kernel (degree = 2)



(4)

比較兩結果可發現使用 polynomial kernel 在分類上有更精細的分法，

而 linear 則較為單一。根據之前學到的，可能是 polynomial kernel 裡

的非線性運算能讓資料在分類上，有著更好的表現。

### 3. Gaussian Mixture Model

$K = 3$ :




K-means K=3				GMM K=3			
	R	G	B		R	G	B
0	73	66	52	0	80	67	58
1	194	195	182	1	128	131	124
2	133	126	104	2	137	125	87

image GMM K = 3




GMM Log likelihood K = 3




K = 5:

K-means K=5				GMM K=5			
	R	G	B		R	G	B
0	213	217	210	0	160	165	165
1	169	167	147	1	141	151	112
2	59	52	39	2	79	65	58
3	93	86	69	3	74	71	60
4	133	125	103	4	126	111	85

image GMM K = 5



GMM Log likelihood K = 5




K = 7:

K-means K=7				GMM K=7			
	R	G	B		R	G	B
0	49	42	30	0	70	62	38
1	186	189	175	1	153	165	164
2	76	68	56	2	76	63	56
3	103	96	77	3	106	96	81
4	160	156	132	4	126	130	73
5	133	125	103	5	155	141	114
6	225	229	225	6	161	166	168

image GMM K = 7



GMM Log likelihood K = 7




K = 10:

K-means K=10				GMM K=10			
	R	G	B		R	G	B
0	90	84	69	0	87	84	72
1	231	233	229	1	227	228	228
2	44	38	25	2	62	55	35
3	199	184	130	3	126	130	71
4	188	195	192	4	173	179	170
5	155	139	103	5	161	147	116
6	151	159	157	6	149	153	151
7	118	124	122	7	115	121	124
8	70	62	49	8	78	65	58
9	119	108	82	9	126	107	83

image GMM K = 10



GMM Log likelihood K = 10



再補上 K-means 的圖:

image K-means  $K = 3$



image K-means  $K = 5$





image K-means  $K = 7$



image K-means  $K = 10$



(5)

由觀察可發現， $K$  值是影響輸出圖像非常關鍵的因素。當  $K$  值越來越大時，成像越清晰，Log likelihood 也較大。